Regresión múltiple y logística

Prof. Rashid C.J. Marcano Rivera

SOCI 6015 - Métodos cuantitativos
Departamento de Sociología y Antropología
Facultad de Ciencias Sociales
Universidad de Puerto Rico
Recinto de Río Piedras

5 de diciembre de 2024

Sección 0: Cerrando donde nos quedamos

Cálculos adicionales

Intervalos de confianza para coeficientes

Definición

Un intervalo de confianza es el rango frecuentista alrededor del estimado de un coeficiente que tiene una probabilidad determinada $(1-\alpha)$ de contener el verdadero valor del parámetro:

$$\hat{\beta}_k \pm t_{(1-\alpha/2),n-K} \cdot SE(\hat{\beta}_k),$$

donde:

- $t_{(1-\alpha/2),n-K}$: valor crítico de la distribución t con $n-K$ grados de libertad.
- $SE(\hat{\beta}_k)$: error estándar del coeficiente.

N.B.: Aumentar el tamaño de la muestra reduce $SE(\hat{\beta}_k)$, estrechando el intervalo, como se ha visto antes al trabajar con potencia.

Error estándar de un coeficiente: Fórmula general

Definición

El error estándar de un coeficiente estimado $\hat{\beta}_k$ se calcula como:

$$SE(\hat{\beta}_k) = \sqrt{\sigma^2 \cdot S_{kk}},$$

donde:

- $\sigma^2 = \frac{\mathbf{e}^\intercal \mathbf{e}}{n-K}$ es la varianza residual, con $\mathbf{e} = \mathbf{y} - \widehat{\mathbf{y}}$ el vector de residuos. $\mathbf{e}^\intercal \mathbf{e}$ es la suma de los cuadrados residuales (SSR)
- S_{kk} es el elemento diagonal correspondiente al predictor k en la matriz $(\mathbf{X}^\intercal \mathbf{X})^{-1}$.

N.B.: S_{kk} refleja la contribución del predictor k al modelo y está relacionado con la estructura de la matriz de diseño.

Cálculo paso a paso del error estándar

Pasos principales

1. **Calcular $\mathbf{X}^\intercal\mathbf{X}$:** Multiplica la matriz de diseño $\mathbf{X}$ por su transpuesta.
2. **Invertir $\mathbf{X}^\intercal\mathbf{X}$:** Obtén $(\mathbf{X}^\intercal\mathbf{X})^{-1}$.
3. **Extraer S_{kk}:** Toma el k-ésimo elemento diagonal de $(\mathbf{X}^\intercal\mathbf{X})^{-1}$.
4. **Calcular σ^2:** Divide la suma de cuadrados residuales $(\mathbf{e}^\intercal\mathbf{e})$ entre $n-K$.
5. **Combinar:** Sustituye σ^2 y S_{kk} en:

$$SE(\hat{\beta}_k) = \sqrt{\frac{\mathbf{e}^\intercal\mathbf{e}}{n-K} \cdot S_{kk}}.$$

Relación con la prueba t

Prueba t para coeficientes

La prueba t evalúa la hipótesis nula:

$$H_0 : \beta_k = 0 \quad \text{vs} \quad H_1 : \beta_k \neq 0.$$

El estadístico de prueba se calcula como:

$$t_k = \frac{\hat{\beta}_k}{SE(\hat{\beta}_k)},$$

que sigue una distribución t con $n - K$ grados de libertad bajo H_0.

Un coeficiente es significativo si el intervalo de confianza no incluye 0. Esto equivale a rechazar H_0 en la prueba t con el mismo nivel de confianza:

$$\text{Rechazar } H_0 \iff \text{el intervalo no contiene } 0.$$

Prueba F en regresión

Definición

La prueba F evalúa si el modelo completo de regresión mejora significativamente la predicción en comparación con un modelo nulo (solo incluye la media):

$$H_0 : \beta_1 = \beta_2 = \ldots = \beta_k = 0 \quad \text{vs} \quad H_1 : \text{al menos uno } \beta_k \neq 0.$$

El estadístico F se calcula como:

$$F = \frac{\text{Varianza explicada por el modelo}/k}{\text{Varianza no explicada (residual)}/(n-k-1)},$$

donde:

- k: número de predictores en el modelo.
- n: tamaño de la muestra.

Sigue una distribución $F(k, n-k-1)$ bajo H_0.

Nota: Un p-valor pequeño indica que el modelo tiene al menos un coeficiente significativo.

Relación con R^2

Interpretación

La prueba F también está relacionada con el coeficiente de determinación R^2, que mide la proporción de la varianza total explicada por el modelo:

$$F = \frac{R^2/k}{(1-R^2)/(n-k-1)}.$$

Un R^2 alto, combinado con un p-valor pequeño en la prueba F, indica que el modelo explica significativamente la variación en los datos.

La prueba F sirve para evaluar la utilidad general o global del modelo en conjunto, complementando las pruebas t de los coeficientes individuales.

¿Qué pasa si las presunciones se violan?

Cuando una o más presunciones del modelo OLS no se cumplen, el modelo puede ser inválido o ineficiente. Algunas situaciones comunes incluyen:

- **Violación de la linealidad:** La relación entre $\mathbf{Y}$ y $\mathbf{X}$ no es lineal.
- **Variable dependiente no continua:** Si Y es categórica o binaria, OLS no es adecuado.
- **Heterocedasticidad:** Los errores no tienen una varianza constante.
- **Autocorrelación:** Los errores están correlacionados entre sí (común en datos temporales).
- **Multicolinealidad severa:** Predictores altamente correlacionados.

Modelos alternativos según la violación

Dependiendo de la presunción que se viola, podemos considerar otros modelos:

- **Violación de la linealidad:**
  - Transformaciones no lineales (e.g., $\log(Y)$, Y^2).
  - Modelos no paramétricos o GAM (*Generalized Additive Models*).
- **Variable dependiente categórica:**
  - Modelos logísticos (binarios, multinomiales u ordinales).
  - Modelos probit.
- **Heterocedasticidad:**
  - Modelos de regresión ponderada (*Weighted Least Squares, WLS*).
  - Estimadores robustos de la varianza.
- **Autocorrelación:**
  - Modelos para series temporales (e.g., ARIMA).
- **Multicolinealidad severa:**
  - Reducción de dimensionalidad (e.g., análisis de componentes principales).
  - Modelos ridge o lasso.

Próxima sección: ¿Cuándo y por qué usar modelos logísticos?

Sección 1: Regresión logística

Modelos probabilísticos

¿Por qué usar regresión logística?

Situación: Si la variable dependiente (Y) es categórica o binaria, el modelo OLS no es adecuado porque:

- El modelo lineal puede predecir valores fuera del rango de probabilidades ($[0, 1]$).
- La relación entre X y Y no es lineal.
- Los errores no son homocedásticos ni normalmente distribuidos.

Solución: Regresión logística

Regresión logística: Introducción

La **regresión logística** es un modelo adecuado cuando la variable dependiente (Y) es categórica o binaria ($Y \in \{0, 1\}$).
Idea clave: Modelar la probabilidad de ocurrencia de un evento ($P(Y = 1 \mid X)$) usando una función logística:

$$P(Y = 1 \mid X) = \frac{\exp(\beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k)}{1 + \exp(\beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k)}.$$

En términos de log-odds (logit), la relación es lineal:

$$\text{logit}(P) = \ln\left(\frac{P}{1 - P}\right) = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k.$$

Donde:

- P: Probabilidad de que $Y = 1$.
- $\beta_0, \beta_1, \ldots, \beta_k$: Coeficientes del modelo.
- $X_1, X_2, \ldots, X_k$: Variables predictoras.

Cómo se ve

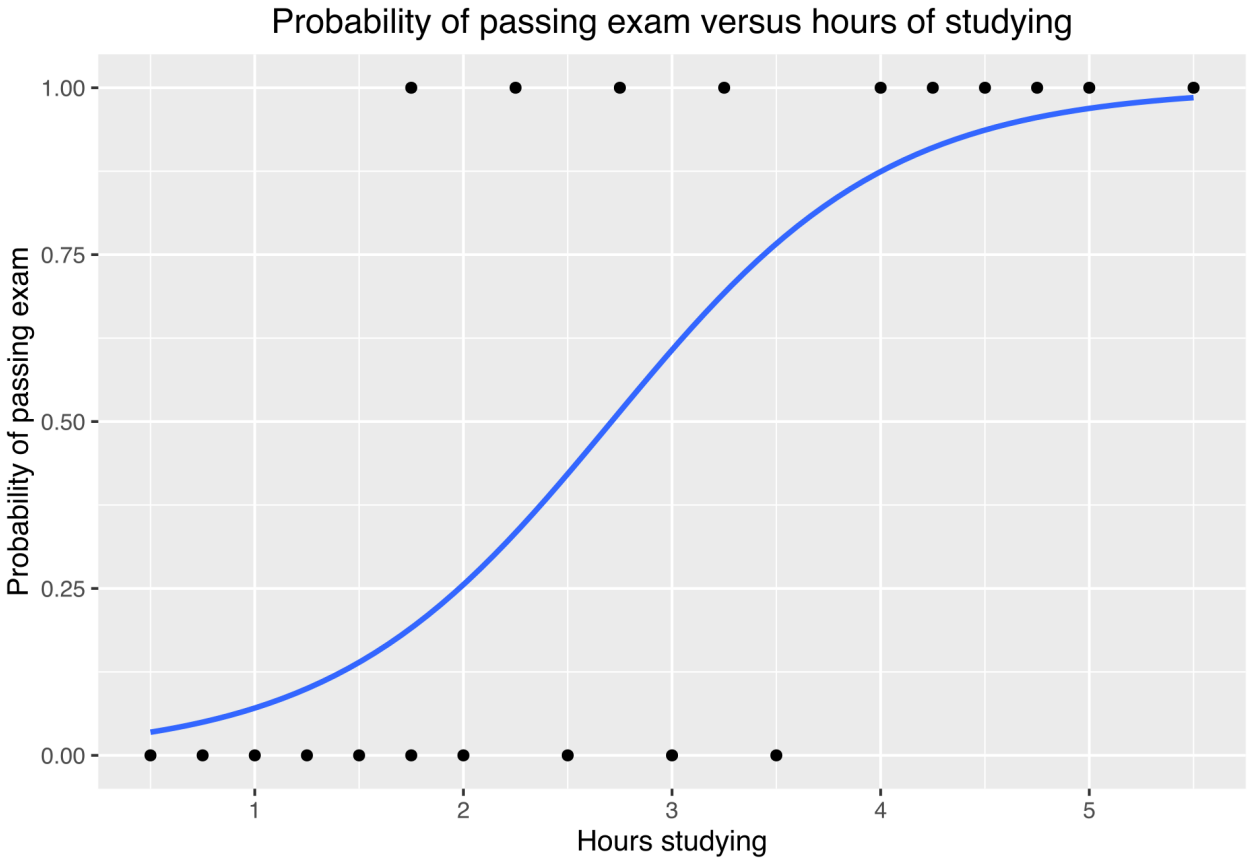

Figura: Gráfica de regresión logística. La curva muestra la probabilidad estimada de aprobar un examen (dependiente binaria) dadas horas de estudio (escalar independiente).

Regresión logística: Notación matricial

En **notación matricial**, la regresión logística se formula como:

$$\mathbf{P} = \frac{\exp(\mathbf{X}\boldsymbol{\beta})}{1 + \exp(\mathbf{X}\boldsymbol{\beta})},$$

donde:

- $\mathbf{P} \in \mathbb{R}^n$: Vector columna de probabilidades predichas ($P(Y_i = 1)$).
- $\mathbf{X} \in \mathbb{R}^{n \times (k+1)}$: Matriz de diseño (incluye columna de 1s para el intercepto).
- $\boldsymbol{\beta} \in \mathbb{R}^{(k+1)}$: Vector de coeficientes desconocidos.

En términos de logit:

$$\text{logit}(\mathbf{P}) = \ln\left(\frac{\mathbf{P}}{1 - \mathbf{P}}\right) = \mathbf{X}\boldsymbol{\beta}.$$

Nota: Este modelo no tiene solución cerrada como OLS. Los coeficientes se estiman usando métodos iterativos, como la máxima verosimilitud.

Concepto de verosimilitud

Definición

En estadística, la **función de verosimilitud** es una función de los parámetros de un modelo estadístico que permite realizar inferencias sobre su valor a partir de un conjunto de observaciones. Se representa como:

$$\mathcal{L}(\boldsymbol{\beta}) = P(\mathbf{Y} \mid \mathbf{X}, \boldsymbol{\beta}),$$

donde $\mathbf{Y}$ son los datos observados, $\mathbf{X}$ los predictores y $\boldsymbol{\beta}$ los parámetros del modelo.

Diferencia con la probabilidad

La **probabilidad** evalúa la ocurrencia de ciertos valores de la variable aleatoria dados los parámetros conocidos del modelo. En cambio, la **verosimilitud** evalúa qué tan plausible es un conjunto de parámetros para explicar los datos observados. Es una función de los parámetros, no de los datos.

Concepto de verosimilitud

Historia del término

- El término inglés *likelihood* apareció originalmente con un vínculo débil al concepto de probabilidad.
- Su uso moderno se debe a R.A. Fisher, quien formalizó el término en su artículo *On the mathematical foundations of theoretical statistics* (1922).
- Orígenes tempranos: Thiele y Peirce contribuyeron al desarrollo inicial del concepto.

Concepto de verosimilitud y log-verosimilitud

Verosimilitud ($\mathcal{L}(\boldsymbol{\beta})$)

La verosimilitud mide la probabilidad de observar los datos dados los parámetros del modelo ($\boldsymbol{\beta}$). Es una función que evalúa qué tan bien un modelo describe los datos observados:

$$\mathcal{L}(\boldsymbol{\beta}) = P(\mathbf{Y} \mid \mathbf{X}, \boldsymbol{\beta}).$$

Log-verosimilitud ($\ell(\boldsymbol{\beta})$)

La log-verosimilitud es el logaritmo natural de la verosimilitud. Se utiliza para simplificar cálculos y mejorar la estabilidad numérica:

$$\ell(\boldsymbol{\beta}) = \ln(\mathcal{L}(\boldsymbol{\beta})).$$

Maximizar la log-verosimilitud es equivalente a maximizar la verosimilitud.

Verosimilitud ($\mathcal{L}(\boldsymbol{\beta})$)

Definición: La verosimilitud se calcula como el producto de las probabilidades para cada observación en los datos. En el caso de una regresión logística:

$$\mathcal{L}(\boldsymbol{\beta}) = \prod_{i=1}^{n} P(Y_i \mid \mathbf{X}_i, \boldsymbol{\beta})^{Y_i} (1 - P(Y_i \mid \mathbf{X}_i, \boldsymbol{\beta}))^{1-Y_i}.$$

Donde:

- $P(Y_i \mid \mathbf{X}_i, \boldsymbol{\beta})^{Y_i}$: Contribución de los casos donde $Y_i = 1$.
- $(1 - P(Y_i \mid \mathbf{X}_i, \boldsymbol{\beta}))^{1-Y_i}$: Contribución de los casos donde $Y_i = 0$.

Verosimilitud ($\mathcal{L}(\boldsymbol{\beta})$ ejemplo)

Ejemplo: Supongamos un modelo logístico con $n = 3$ observaciones:

$$P(Y_i \mid \mathbf{X}_i, \boldsymbol{\beta}) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_i)}},$$

con $\beta_0 = -1$, $\beta_1 = 0{,}5$, y $X = [1, 2, 3]$. Para $Y = [1, 0, 1]$:

- $P(Y_1 = 1) = \frac{1}{1+e^{-(-1+0{,}5\cdot 1)}} = 0{,}3775.$
- $P(Y_2 = 0) = 1 - \frac{1}{1+e^{-(-1+0{,}5\cdot 2)}} = 0{,}6225.$
- $P(Y_3 = 1) = \frac{1}{1+e^{-(-1+0{,}5\cdot 3)}} = 0{,}8176.$

Verosimilitud total:

$$\mathcal{L}(\boldsymbol{\beta}) = 0{,}3775 \cdot 0{,}6225 \cdot 0{,}8176 = 0{,}1915.$$

Interpretación: El modelo con estos parámetros tiene una probabilidad del 19.15 % de haber generado los datos observados.

Log-verosimilitud ($\ell(\boldsymbol{\beta})$)

Definición: La log-verosimilitud es el logaritmo natural de la verosimilitud:

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^{n} \left[Y_i \ln P(Y_i \mid \mathbf{X}_i, \boldsymbol{\beta}) + (1 - Y_i) \ln(1 - P(Y_i \mid \mathbf{X}_i, \boldsymbol{\beta})) \right].$$

Ejemplo (continuación): Para $P(Y_1 = 1) = 0{,}3775$, $P(Y_2 = 0) = 0{,}6225$, $P(Y_3 = 1) = 0{,}8176$:

- $Y_1 \ln P(Y_1) = 1 \cdot \ln(0{,}3775) = -0{,}9749$,
- $(1 - Y_2) \ln(1 - P(Y_2)) = 1 \cdot \ln(0{,}6225) = -0{,}4749$,
- $Y_3 \ln P(Y_3) = 1 \cdot \ln(0{,}8176) = -0{,}2015$.

Log-verosimilitud total:

$$\ell(\boldsymbol{\beta}) = -0{,}9749 + (-0{,}4749) + (-0{,}2015) = -1{,}6513.$$

Interpretación: Valores más altos (menos negativos) de $\ell(\boldsymbol{\beta})$ indican un mejor ajuste del modelo a los datos.

Estimación por máxima verosimilitud

La estimación de los coeficientes $\boldsymbol{\beta}$ en regresión logística se basa en el principio de máxima verosimilitud, que busca maximizar la probabilidad de observar los datos dados los parámetros:

$$\mathcal{L}(\boldsymbol{\beta}) = \prod_{i=1}^{n} P(Y_i)^{Y_i}(1 - P(Y_i))^{1-Y_i}.$$

Log-verosimilitud:

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^{n} \left[Y_i \ln P(Y_i) + (1 - Y_i) \ln(1 - P(Y_i)) \right].$$

Estimación:

$$\hat{\boldsymbol{\beta}} = \arg\max_{\boldsymbol{\beta}} \ell(\boldsymbol{\beta}).$$

Estimación por máxima verosimilitud

Diferencias clave con OLS:

- En OLS, la solución es analítica y directa:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\intercal \mathbf{X})^{-1} \mathbf{X}^\intercal \mathbf{Y}.$$

- En MLE, no existe una solución cerrada debido a la naturaleza no lineal del modelo logístico.

Métodos numéricos necesarios en MLE:

- **Descenso por gradiente:** Ajusta $\boldsymbol{\beta}$ iterativamente en la dirección que maximiza $\ell(\boldsymbol{\beta})$.
- **Algoritmo de Newton-Raphson:** Utiliza derivadas de primer y segundo orden para encontrar la raíz de $\frac{\partial \ell(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} = 0$, acelerando la convergencia.

Nota: Estas iteraciones garantizan la convergencia en la mayoría de los casos, pero requieren inicializaciones adecuadas y cuidado con posibles problemas de convergencia.

Interpretación de los coeficientes

Coeficientes (β_j): Representan el efecto de X_j sobre los log-odds ($\ln(P/(1-P))$):

$$\beta_j = \text{Cambio en los log-odds por unidad adicional en } X_j.$$

Odds ratio: El efecto se puede expresar en términos de probabilidades relativas:

$$OR_j = \exp(\beta_j).$$

Interpretación:

- $OR_j > 1$: Incremento en X_j aumenta la probabilidad de $Y = 1$.
- $OR_j < 1$: Incremento en X_j disminuye la probabilidad de $Y = 1$.
- $OR_j = 1$: X_j no tiene efecto.

Si $OR_j = 0{,}8$, un incremento de una unidad en X_j reduce las probabilidades de $Y = 1$ en un 20 %.

Ejemplo práctico: Predicción de aprobación de un curso

Supongamos los siguientes datos:

- $Y = 1$: Aprobó el curso; $Y = 0$: No aprobó el curso.
- Predictores: X_1 (horas de estudio), X_2 (asistencia al curso en porcentaje).

Modelo:

$$\ln\left(\frac{P}{1-P}\right) = \beta_0 + \beta_1 \text{Horas} + \beta_2 \text{Asistencia}.$$

Supongamos:

$$\hat{\beta}_0 = -1{,}5, \quad \hat{\beta}_1 = 0{,}8, \quad \hat{\beta}_2 = 0{,}05.$$

Ejemplo práctico: Predicción de aprobación de un curso

Si:

$$\hat{\beta}_0 = -1{,}5, \quad \hat{\beta}_1 = 0{,}8, \quad \hat{\beta}_2 = 0{,}05.$$

Predicción para un estudiante con:

- $X_1 = 5$ (5 horas de estudio).
- $X_2 = 80\,\%$ de asistencia.

Cálculo:

$$\ln\left(\frac{P}{1-P}\right) = -1{,}5 + (0{,}8 \cdot 5) + (0{,}05 \cdot 80) = 2{,}5.$$

$$P = \frac{\exp(2{,}5)}{1+\exp(2{,}5)} \approx 0{,}924.$$

Interpretación: El estudiante tiene una probabilidad del 92.4 % de aprobar.

Evaluación del modelo

1. **Pseudo-R^2:** Medidas como el de McFadden indican la bondad del ajuste:

$$R^2 = 1 - \frac{\ell(\hat{\boldsymbol{\beta}})}{\ell(\boldsymbol{\beta}_0)}.$$

2. **Pruebas de significancia:**
   - Test de Wald: Evalúa la significancia de cada coeficiente.
   - Test de verosimilitud: Compara modelos anidados.
3. **Matriz de confusión:** Evalúa la capacidad predictiva.

$$\begin{bmatrix} TP & FP \\ FN & TN \end{bmatrix}$$

4. **Curva ROC:** Analiza sensibilidad y especificidad.