Estadísticas: una (re-)introducción

Prof. Rashid C.J. Marcano Rivera

SOCI 6015 - Métodos cuantitativos
Departamento de Sociología y Antropología
Facultad de Ciencias Sociales
Universidad de Puerto Rico
Recinto de Río Piedras

10 de septiembre de 2024

Empezando con Muestra y Población

Muestra y Población

- **Población:** Es el conjunto completo de elementos de interés. Por ejemplo, en una olla de habichuelas, la población sería todas las habichuelas en la olla.
- **Muestra:** Es una parte de la población de la cual obtenemos información. En el ejemplo, una cucharada de habichuelas representa la muestra.
- En la investigación en ciencias sociales y del comportamiento, trabajamos con muestras (como 50 estudiantes de escuela elemental en un experimento) para hacer inferencias sobre una población más grande (como todos los estudiantes de escuela elemental del país).

Ejemplo de Encuesta:

- Una muestra podría ser 1,000 personas seleccionadas para una encuesta de opinión.
- La población sería el público votante en general, al que los encuestadores esperan aplicar los resultados.

Validación Interna y Externa

Validez Interna:

- Se refiere a la precisión con la que un estudio mide lo que pretende medir.
- Un estudio tiene alta validez interna si los resultados observados son realmente atribuibles a las variables manipuladas, sin influencia de factores externos.

Validez Externa:

- Se refiere a la capacidad de generalizar los resultados de un estudio a otras situaciones o poblaciones fuera del contexto experimental.
- Un estudio con alta validez externa permite aplicar sus hallazgos a una población más amplia o a diferentes contextos.

¿Por qué muestreamos?

1. **Generalización (validación externa):**
   - Grado en que los resultados de un estudio se aplican a una población más amplia.
   - E.g. 1: Bajo qué condiciones es más probable que las personas apoyen a líderes autoritarios.
   - E.g. 2: Qué explica el retroceso democrático en Polonia.
   - La capacidad de generalizar depende de un muestreo adecuado.

2. **Variación en Muestras Pequeñas:**
   - En la investigación, en especial cualitativa, es crucial asegurar suficiente variabilidad dentro de una muestra pequeña para obtener resultados significativos.

Muestra y Población

El **muestreo** es el proceso de seleccionar casos de la población para incluirlos en la muestra.

Cada punto representa un caso en una **unidad de análisis**

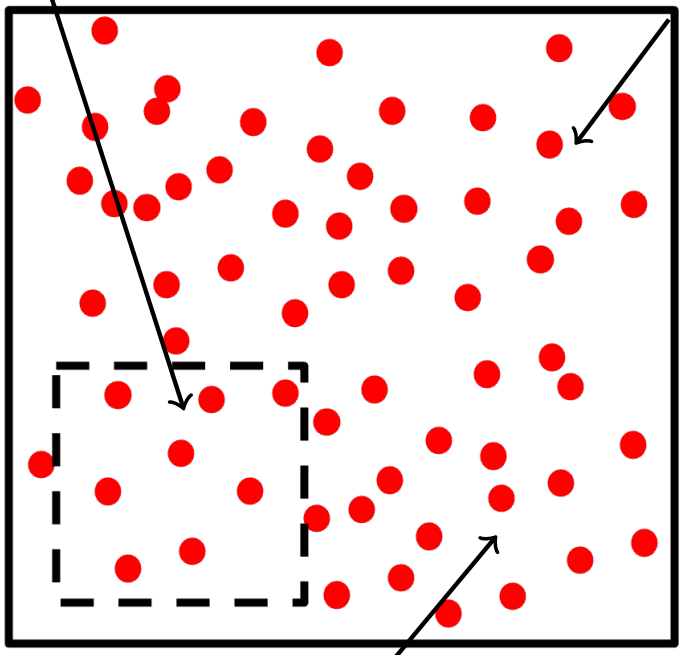

La **población** consiste en todos los puntos.

Muestra y Población

El **muestreo** es el proceso de seleccionar casos de la población para incluirlos en la muestra.

Cada punto representa un caso en una **unidad de análisis**

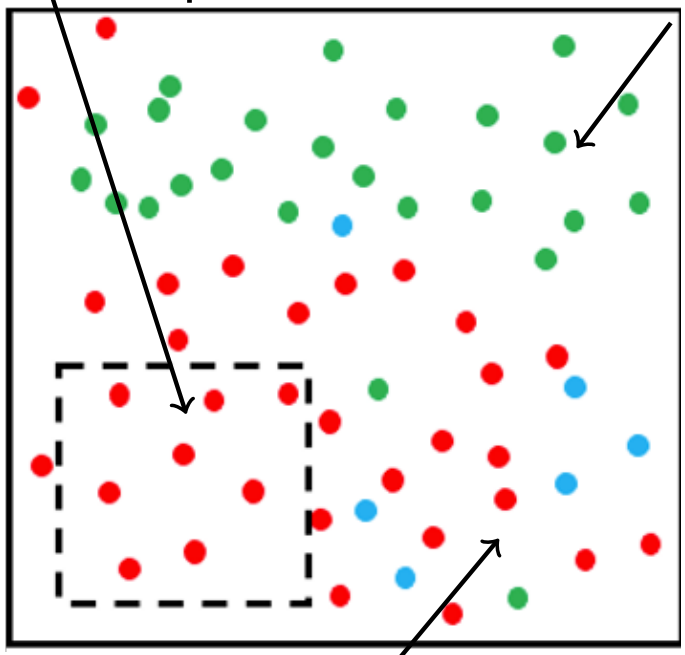

La **población** consiste en todos los puntos.

Tipos de muestreo

Muestreo Probabilístico

La probabilidad de ser seleccionado en la muestra es conocida para todos los miembros de la población.

Generalizable

*Los datos de un muestreo probabilístico **pueden** utilizarse para hacer inferencias sobre la población más amplia.*

Muestreo No probabilístico

La probabilidad de ser seleccionado en la muestra es desconocida para los miembros de la población.

No generalizable

*Los datos de un muestreo no probabilístico **no pueden** utilizarse para hacer inferencias sobre la población más amplia.*

Tipos de muestreo aleatorio

1. **Muestreo aleatorio simple**
   - La probabilidad de selección es la misma para todos los casos en la población (es igual al tamaño de la muestra dividido por el tamaño de la población).

Tipos de muestreo aleatorio

2. **Muestreo estratificado**
   - Divida a los miembros de la población en estratos (grupos homogéneos) basados en alguna característica relevante (ej. género, edad).
   - Cree un marco muestral para cada estrato.
   - **Proporcional:** Seleccione aleatoriamente casos de cada uno de los marcos muestrales en proporción a la participación del estrato en la población.
   - **No proporcional:** Sobremuestree uno o más estratos; la muestra ya no es aleatoria, pero sigue siendo probabilística (es decir, la probabilidad de selección ya no es igual, pero sigue siendo conocida). Se puede usar ponderación para corregir el muestreo estratificado no proporcional.

Tipos de muestreo aleatorio

3. **Muestreo por conglomerados (Cluster Sampling)**
   - Identifique «conglomerados» de casos, como unidades geográficas; un conglomerado es un grupo diverso de casos en la población que ocurre de manera natural.
   - Cree un marco muestral de todos los conglomerados.
   - Seleccione aleatoriamente algunos de los conglomerados (o en proporción al tamaño de cada conglomerado).
   - Tome todos los casos dentro de los conglomerados seleccionados o seleccione aleatoriamente algunos casos dentro de los conglomerados seleccionados.

Parámetros de población y estadísticas de muestra

Parámetros de Población:

- La media, varianza y desviación estándar de una población se llaman parámetros de población.
- Un parámetro de población usualmente es desconocido y solo puede ser estimado a partir de la información de una muestra de esa población.
- No se prueban todas las habichuelas, solo una cucharada. Decir "las habichuelas están listas" es una inferencia sobre toda la olla.

Parámetros de población y estadísticas de muestra

Estadísticas de Muestra:

- La media, varianza y desviación estándar que se calculan para las puntuaciones en una muestra se llaman estadísticas de muestra.
- Una estadística de muestra se calcula a partir de información conocida. Las estadísticas de muestra son lo que hemos estado calculando todo el tiempo.

Parámetros de población y estadísticas de muestra

Símbolos de Población y Muestra:

- **Media de la Población (mu)**: μ vs. **Media de la Muestra (x-barra)**: $\bar{x}$
- **Varianza de la Población**: σ^2 vs. **Varianza de la Muestra**: s^2
- **Desviación Estándar de la Población**: σ vs. **Desviación Estándar de la Muestra**: s

Parámetros de población y estadísticas de muestra

Comparación de los símbolos:

Concepto	**Población (Parámetro)**	**Muestra (Estadística)**
Media	μ	$\bar{x}$
Varianza	σ^2	s^2
Desv. Est.	σ	s

Esta tabla muestra las diferencias en los símbolos usados para los parámetros de la población y las estadísticas de la muestra en clase.

Fórmulas: Parámetros de Población vs. Estadísticas de Muestra

Fórmulas Comparativas:

Concepto	Población (Parámetro)	Muestra (Estadística)
Media	$\mu = \frac{\sum X}{N}$	$\bar{x} = \frac{\sum X}{n}$
Varianza	$\sigma^2 = \frac{\sum (X-\mu)^2}{N}$	$s^2 = \frac{\sum (X-\bar{x})^2}{n-1}$
Desv. Est.	$\sigma = \sqrt{\frac{\sum (X-\mu)^2}{N}}$	$s = \sqrt{\frac{\sum (X-\bar{x})^2}{n-1}}$

En la muestra, se usa $n-1$ en lugar de n para corregir el sesgo en la estimación de la varianza y desviación estándar, lo que se conoce como el «grados de libertad» en el cálculo.

Probabilidad

- En estadística, la probabilidad se define como la frecuencia relativa esperada de un resultado particular.
- Un resultado es el desenlace de un experimento o situación en la que no se conoce el resultado de antemano (como que salga cara al lanzar una peseta o que mañana llueva).

Probabilidad (cont.)

Figura: Peseta (20 centavos, o un quinto de peso), 1895

- **Frecuencia:** Cuántas veces ocurre algo.
- **Frecuencia relativa:** La cantidad de veces que ocurre algo en relación con la cantidad de veces que pudo haber ocurrido. (Ejemplo: Cara en 8 de 12 lanzamientos de una peseta, frecuencia relativa $= \frac{8}{12} = \frac{2}{3}$).

Probabilidad (cont.)

Figura: Ficha (5 centavos), 1896

Figura: Vellón (10 centavos), 1896

- **Frecuencia relativa esperada:** Lo que esperas obtener a largo plazo, si repites el experimento muchas veces. (En el caso de la peseta, vellón o ficha, a largo plazo esperas obtener $\frac{1}{2}$ caras).
- Esto se llama la interpretación de la probabilidad como «frecuencia relativa a largo plazo».

Cálculo de probabilidades

Las probabilidades generalmente se calculan como la proporción de resultados posibles exitosos: el número de resultados exitosos posibles dividido por el número de todos los resultados posibles. Es decir,

$$\text{Probabilidad} = \frac{\text{Resultados exitosos posibles}}{\text{Todos los resultados posibles}}$$

- Ejemplo 1: Probabilidad de obtener cara al lanzar una peseta.
  - Solo hay un resultado exitoso (cara) de dos posibles resultados (cara o cruz).
  - **Probabilidad** $= \frac{1}{2} = 0{,}5$.
- Ejemplo 2: Probabilidad de obtener un 2 al lanzar un dado.
  - Solo hay un resultado exitoso (un 2) de seis posibles resultados.
  - **Probabilidad** $= \frac{1}{6} \approx 0{,}17$.

Cálculo de probabilidades

- Ejemplo 3: Probabilidad de obtener un número 3 o menor al lanzar un dado.
  - Hay tres resultados exitosos (1, 2 o 3) de seis posibles resultados.
  - **Probabilidad** $= \frac{3}{6} = 0{,}5$.
- Ejemplo 4: Probabilidad de elegir a un estudiante de último año en una clase con 200 personas, de las cuales 30 son estudiantes de último año.
  - Hay 30 resultados exitosos (estudiantes de último año) de 200 posibles resultados.
  - **Probabilidad** $= \frac{30}{200} = 0{,}15$.

“p” o $\mathbb{P}$ para probabilidad

- La probabilidad usualmente se simboliza con la letra p.
- El número de probabilidad normalmente se expresa como un decimal, aunque también se pueden usar fracciones o porcentajes.
  - Ejemplo: $p = 0{,}5$, $p = \frac{1}{2}$, o $p = 50\,\%$ representan una probabilidad del 50 %.
- También es común ver la probabilidad escrita como menor que un número usando el signo de “menor que”:
  - Ejemplo: $p < 0{,}05$ significa “la probabilidad es menor que 0.05”.
- Otra notación que se puede utilizar es el símbolo de probabilidad $\mathbb{P}$, especialmente en algunos textos matemáticos o estadísticos.
  - Ejemplo: $\mathbb{P}(X < 10) = 0{,}2$, donde $\mathbb{P}$ denota la probabilidad de que X sea menor que 10.

Conectando los conceptos: Probabilidad, puntajes Z y la distribución normal (1/2)

- **Probabilidad de rangos:** Además de eventos específicos, podemos calcular la probabilidad de rangos de eventos, como lanzar un dado y obtener un 3 o menos, o seleccionar una persona de entre 30 y 40 años de una población.
- **Distribuciones de frecuencia:** La probabilidad está relacionada con la proporción de puntajes en una distribución de frecuencia. Ejemplo: si 3 de 50 personas obtienen un puntaje de 9 o 10, $p = \frac{3}{50} = 0{,}06$.
- **Distribución normal como distribución de probabilidad:** En una curva normal, el porcentaje de puntajes entre dos puntajes Z es equivalente a la probabilidad de seleccionar un puntaje en ese rango. Por ejemplo, la probabilidad entre la media y un $Z = +1$ es $p = 0{,}34$.

Conectando los conceptos: Probabilidad, puntajes Z y la distribución normal (2/2)

- **Probabilidad en la curva normal:** Aproximadamente el 95 % de los puntajes en una distribución normal están entre $Z = -1{,}96$ y $Z = +1{,}96$, lo que significa que la probabilidad de seleccionar un puntaje en este rango es $p = 0{,}95$. La probabilidad de obtener un puntaje fuera de este rango es $p = 0{,}05$.
- **Probabilidad y muestras/poblaciones:** Comparar un puntaje de muestra con una población ayuda a determinar la probabilidad de que el puntaje provenga de esa población. Si el puntaje es raro, la probabilidad es baja.
- **Probabilidad en investigación:** En artículos, la probabilidad se menciona con frecuencia en relación a la significancia estadística, usando notaciones como $p < 0{,}05$, indicando la probabilidad de que los resultados observados sean significativos.

¿Qué es probar hipótesis?

- **Definición:** La prueba de hipótesis es un proceso estadístico que nos permite tomar decisiones o inferencias sobre una población basándonos en una muestra de datos.

¿Qué es probar hipótesis?

- **Definición:** La prueba de hipótesis es un proceso estadístico que nos permite tomar decisiones o inferencias sobre una población basándonos en una muestra de datos.
- **Importancia:** Es fundamental para evaluar teorías, validar modelos y tomar decisiones informadas en investigación.

¿Qué es probar hipótesis?

- **Definición:** La prueba de hipótesis es un proceso estadístico que nos permite tomar decisiones o inferencias sobre una población basándonos en una muestra de datos.
- **Importancia:** Es fundamental para evaluar teorías, validar modelos y tomar decisiones informadas en investigación.
- **Tipos de hipótesis:**

¿Qué es probar hipótesis?

- **Definición:** La prueba de hipótesis es un proceso estadístico que nos permite tomar decisiones o inferencias sobre una población basándonos en una muestra de datos.
- **Importancia:** Es fundamental para evaluar teorías, validar modelos y tomar decisiones informadas en investigación.
- **Tipos de hipótesis:**
  - **Hipótesis nula (H_0):** No hay diferencia o efecto en la población.

¿Qué es probar hipótesis?

- **Definición:** La prueba de hipótesis es un proceso estadístico que nos permite tomar decisiones o inferencias sobre una población basándonos en una muestra de datos.
- **Importancia:** Es fundamental para evaluar teorías, validar modelos y tomar decisiones informadas en investigación.
- **Tipos de hipótesis:**
  - **Hipótesis nula (H_0):** No hay diferencia o efecto en la población.
  - **Hipótesis alternativa (H_1):** Hay una diferencia o efecto en la población.

¿Qué es probar hipótesis?

- **Definición:** La prueba de hipótesis es un proceso estadístico que nos permite tomar decisiones o inferencias sobre una población basándonos en una muestra de datos.
- **Importancia:** Es fundamental para evaluar teorías, validar modelos y tomar decisiones informadas en investigación.
- **Tipos de hipótesis:**
  - **Hipótesis nula (H_0):** No hay diferencia o efecto en la población.
  - **Hipótesis alternativa (H_1):** Hay una diferencia o efecto en la población.
- **Ejemplo:** Queremos probar si el nivel educativo tiene un impacto en la participación política. La hipótesis nula (H_0) sería que no hay relación entre el nivel educativo y la participación política. La hipótesis alternativa (H_1) sería que sí existe una relación entre ambas variables.

Resumen de los pasos para probar hipótesis

1. **Reformular la pregunta:** Como una hipótesis de investigación y una hipótesis nula sobre las poblaciones.
2. **Determinar las características:** Identificar las características de la distribución de comparación.

Resumen de los pasos para probar hipótesis

1. **Reformular la pregunta:** Como una hipótesis de investigación y una hipótesis nula sobre las poblaciones.
2. **Determinar las características:** Identificar las características de la distribución de comparación.
3. **Determinar el punto de corte:** Establecer el valor de la muestra en la distribución de comparación en el que se debe rechazar la hipótesis nula.

Resumen de los pasos para probar hipótesis

1. **Reformular la pregunta:** Como una hipótesis de investigación y una hipótesis nula sobre las poblaciones.
2. **Determinar las características:** Identificar las características de la distribución de comparación.
3. **Determinar el punto de corte:** Establecer el valor de la muestra en la distribución de comparación en el que se debe rechazar la hipótesis nula.
4. **Calcular el puntaje de la muestra:** Encontrar el puntaje de tu muestra en la distribución de comparación.

Resumen de los pasos para probar hipótesis

1. **Reformular la pregunta:** Como una hipótesis de investigación y una hipótesis nula sobre las poblaciones.
2. **Determinar las características:** Identificar las características de la distribución de comparación.
3. **Determinar el punto de corte:** Establecer el valor de la muestra en la distribución de comparación en el que se debe rechazar la hipótesis nula.
4. **Calcular el puntaje de la muestra:** Encontrar el puntaje de tu muestra en la distribución de comparación.
5. **Decidir:** Determinar si se debe rechazar la hipótesis nula.

Pruebas de hipótesis de una cola y dos colas

Hipótesis direccional:

- Una hipótesis de investigación que predice una dirección particular de diferencia entre las poblaciones. Por ejemplo, una predicción de que la población, como la muestra estudiada, tiene una media más alta que la población en general.

Prueba de una cola (one-tailed test):

Pruebas de hipótesis de una cola y dos colas

Hipótesis direccional:

- Una hipótesis de investigación que predice una dirección particular de diferencia entre las poblaciones. Por ejemplo, una predicción de que la población, como la muestra estudiada, tiene una media más alta que la población en general.

Prueba de una cola (one-tailed test):

- Procedimiento para probar una hipótesis direccional; la región de la distribución de comparación en la que se rechazaría la hipótesis nula está completamente en un lado (o cola) de la distribución.

Hipótesis no direccionales y pruebas de dos colas

Hipótesis no direccional:

- Una hipótesis de investigación que predice un efecto, pero no especifica la dirección del efecto. Ejemplo: un programa de habilidades sociales podría afectar la productividad, ya sea aumentándola o disminuyéndola.

Hipótesis no direccionales y pruebas de dos colas

Hipótesis no direccional:

- Una hipótesis de investigación que predice un efecto, pero no especifica la dirección del efecto. Ejemplo: un programa de habilidades sociales podría afectar la productividad, ya sea aumentándola o disminuyéndola.
- La hipótesis de investigación es que el programa cambia el nivel de productividad, mientras que la hipótesis nula es que no cambia la productividad en ninguna dirección.

Prueba de dos colas (Two-Tailed Test):

Hipótesis no direccionales y pruebas de dos colas

Hipótesis no direccional:

- Una hipótesis de investigación que predice un efecto, pero no especifica la dirección del efecto. Ejemplo: un programa de habilidades sociales podría afectar la productividad, ya sea aumentándola o disminuyéndola.
- La hipótesis de investigación es que el programa cambia el nivel de productividad, mientras que la hipótesis nula es que no cambia la productividad en ninguna dirección.

Prueba de dos colas (Two-Tailed Test):

- Para una hipótesis no direccional, se considera la posibilidad de que la muestra sea extrema en cualquiera de los dos extremos (colas) de la distribución de comparación.

Hipótesis no direccionales y pruebas de dos colas

Hipótesis no direccional:

- Una hipótesis de investigación que predice un efecto, pero no especifica la dirección del efecto. Ejemplo: un programa de habilidades sociales podría afectar la productividad, ya sea aumentándola o disminuyéndola.
- La hipótesis de investigación es que el programa cambia el nivel de productividad, mientras que la hipótesis nula es que no cambia la productividad en ninguna dirección.

Prueba de dos colas (Two-Tailed Test):

- Para una hipótesis no direccional, se considera la posibilidad de que la muestra sea extrema en cualquiera de los dos extremos (colas) de la distribución de comparación.
- Se rechaza la hipótesis nula si el puntaje cae en cualquiera de las dos colas de la distribución.

Hipótesis direccionales y pruebas de una cola

Contraste con Hipótesis Direccionales y Pruebas de Una Cola:

- En una **hipótesis direccional**, se predice una dirección específica (por ejemplo, que un programa aumentará la productividad), y la prueba es de una cola.

Hipótesis direccionales y pruebas de una cola

Contraste con Hipótesis Direccionales y Pruebas de Una Cola:

- En una **hipótesis direccional**, se predice una dirección específica (por ejemplo, que un programa aumentará la productividad), y la prueba es de una cola.
- En una **prueba de una cola (one-tailed test)**, solo se considera un extremo de la distribución, ya que el efecto se espera en una dirección particular.

Pruebas de una y dos colas

Diferencia entre Pruebas de Una Cola y Dos Colas

- **Prueba de Una Cola:** Se usa cuando la hipótesis de investigación es direccional, prediciendo un resultado en una dirección específica. El área de rechazo para la hipótesis nula se encuentra en un solo extremo de la distribución.
- **Prueba de Dos Colas:** Se usa cuando la hipótesis de investigación no predice una dirección específica. El área de rechazo está dividida en ambos extremos de la distribución.

Niveles de Significancia y Puntajes Z

Niv. Sign.	Prueba de una cola	Prueba de dos colas
0.05	-1.64 o 1.64	-1.96 y 1.96
0.01	-2.33 o 2.33	-2.58 y 2.58

Pruebas de una y dos colas

Cuándo usar cada tipo de prueba:

- Usa una prueba de **una cola** cuando tienes una hipótesis **direccional** clara:
  - Ejemplo: Hipótesis direccional: «El ingreso promedio de los trabajadores sindicalizados en Puerto Rico es mayor que el de los no sindicalizados.»
- Usa una prueba de **dos colas** para hipótesis **no direccionales** o para estar seguro si el resultado podría ir en cualquier dirección:
  - Ejemplo: Hipótesis no direccional: «El nivel de participación política de las mujeres puertorriqueñas es diferente al de los hombres.» (No se especifica si es mayor o menor, sólo que es diferente.)