# Correlación y predicción

Prof. Rashid C.J. Marcano Rivera

SOCI 6015 - Métodos cuantitativos
Departamento de Sociología y Antropología
Facultad de Ciencias Sociales
Universidad de Puerto Rico
Recinto de Río Piedras

21 de noviembre de 2024

# Sección 0: Recapitulando

Semana abisal

# Sección 0: Recapitulando

En las lecciones anteriores hemos cubierto los siguientes conceptos fundamentales:

- **Conceptos básicos de estadística**: Fundamentos y terminología esencial.
- **Medidas de tendencia central**: Media, mediana y moda.
- **Medidas de dispersión**: Varianza, desviación estándar y rango.
- **Pruebas estadísticas**: Tipos y propósitos de las pruebas en investigación.
- **Significancia estadística**: Entendimiento del p-valor y su interpretación.
- **Distribuciones clave**:
  - Distribución normal
  - Distribución t de Student
  - Distribución F
  - Distribución Chi cuadrado

# Sección 1: Correlación

Introducción

# Sección 1: Introducción a la correlación

La **correlación** mide la relación entre dos variables, indicando cómo cambian juntas, es decir, cómo covarían.

- Mide la dirección y la fuerza de la relación.
- Se usa para identificar patrones o tendencias entre variables.
- **No implica causalidad**; una correlación no significa que una variable cause cambios en la otra.

# Diagrama de dispersión (Scatter Plot)

**Gráficos de dispersión** son una herramienta visual clave para representar la correlación entre dos variables.

- Cada punto en el gráfico representa un par de valores de las dos variables.
- Permite observar la tendencia general (positiva, negativa o nula).

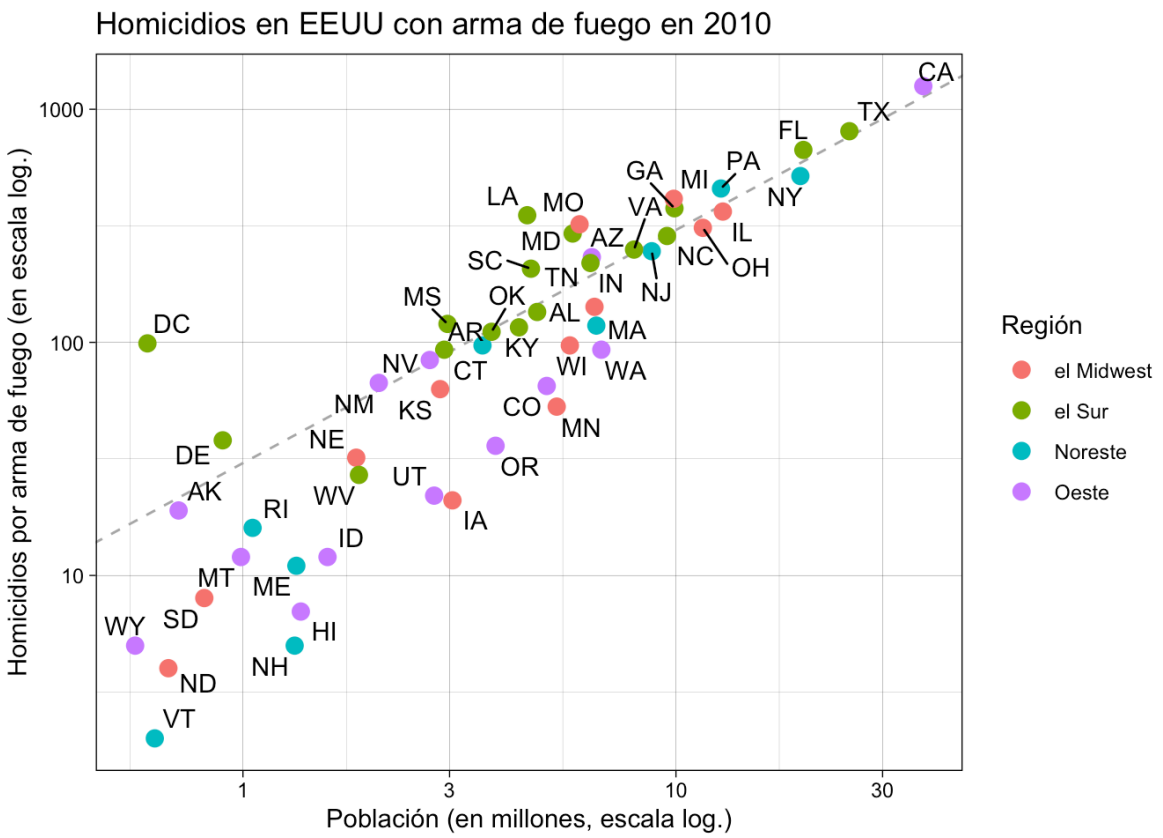

# Tipos de Correlación

Existen varios tipos de correlación según la dirección y forma de la relación entre las variables:

- **Relación directa**: Ambas variables aumentan o disminuyen juntas.
- **Relación inversa**: Una variable aumenta mientras la otra disminuye.
- **Correlación positiva o negativa**: Las variables covarían positivamente, o inversamente.
- **Correlación lineal y curvilínea**: Relación que sigue una línea recta o curva (es recta hasta un punto y cambia).

# Coeficiente de Correlación

El **coeficiente de correlación** cuantifica la relación entre dos variables.

- Representado comúnmente como $r$ (coeficiente de Pearson). Se puede expresar como $\rho$, rho.
- Rango de $-1$ a $+1$:
  - $r = +1$: Correlación positiva perfecta.
  - $r = -1$: Correlación negativa perfecta.
  - $r = 0$: Sin correlación.
- Actividad de práctica https://www.guessthecorrelation.com

# Interpretación del Coeficiente de Correlación

La magnitud del coeficiente de correlación nos permite entender la **fuerza de la relación**:

- **Débil**: $0{,}1 \leq |r| < 0{,}3$
- **Moderada**: $0{,}3 \leq |r| < 0{,}5$
- **Fuerte**: $0{,}5 \leq |r| \leq 1{,}0$

**Nota:** La correlación fuerte **no implica causalidad**.

# Sección 2: Diagrama de dispersión

Nuevamente

# Diagrama de Dispersión: ¿Qué es?

Un **diagrama de dispersión** es una representación gráfica que muestra la relación entre dos variables mediante puntos en un plano.

- Cada punto representa un par de valores (X, Y).
- Se usa para identificar correlación visualmente antes de realizar análisis más complejos.

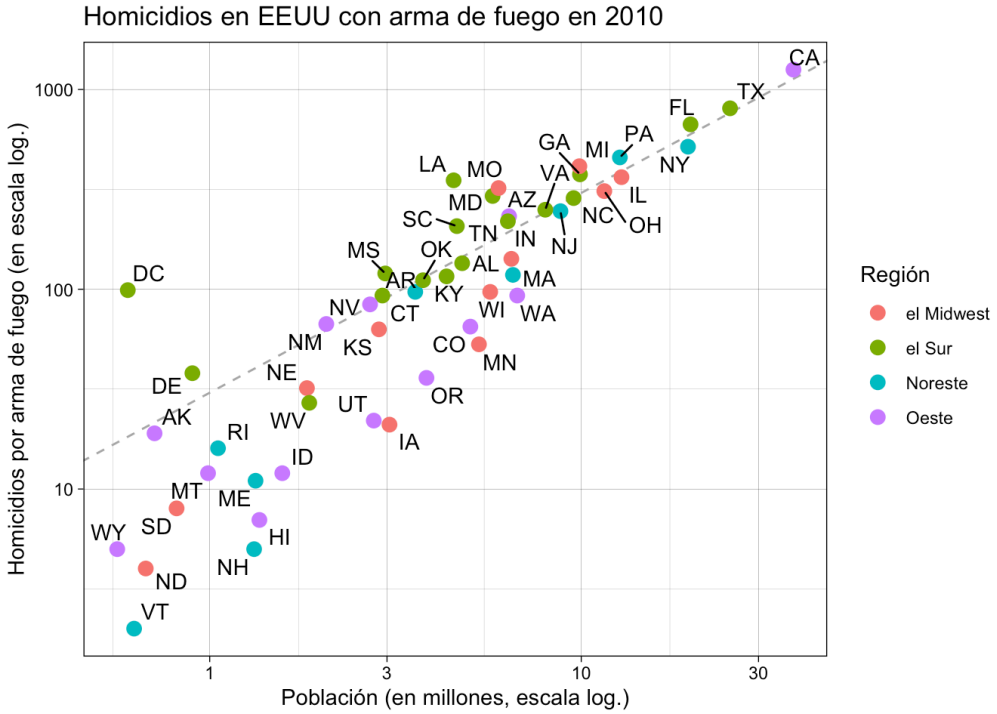

# Cómo construirlo

Pasos para construir un diagrama de dispersión:

1. **Dibujar los ejes:** Coloca una variable en el eje horizontal (X) y otra en el eje vertical (Y).
2. **Determinar los rangos de los ejes:** Los valores deben abarcar el rango completo de ambas variables.
3. **Marcar cada par de valores:** Para cada observación, ubica un punto donde se cruzan los valores de X y Y.

# Interpretación del Diagrama de Dispersión

Un diagrama de dispersión permite identificar distintos **patrones de correlación**:

- **Patrón ascendente:** Indica una posible correlación positiva.
- **Patrón descendente:** Indica una posible correlación negativa.
- **Patrón disperso o sin forma clara:** Puede sugerir poca o ninguna correlación.

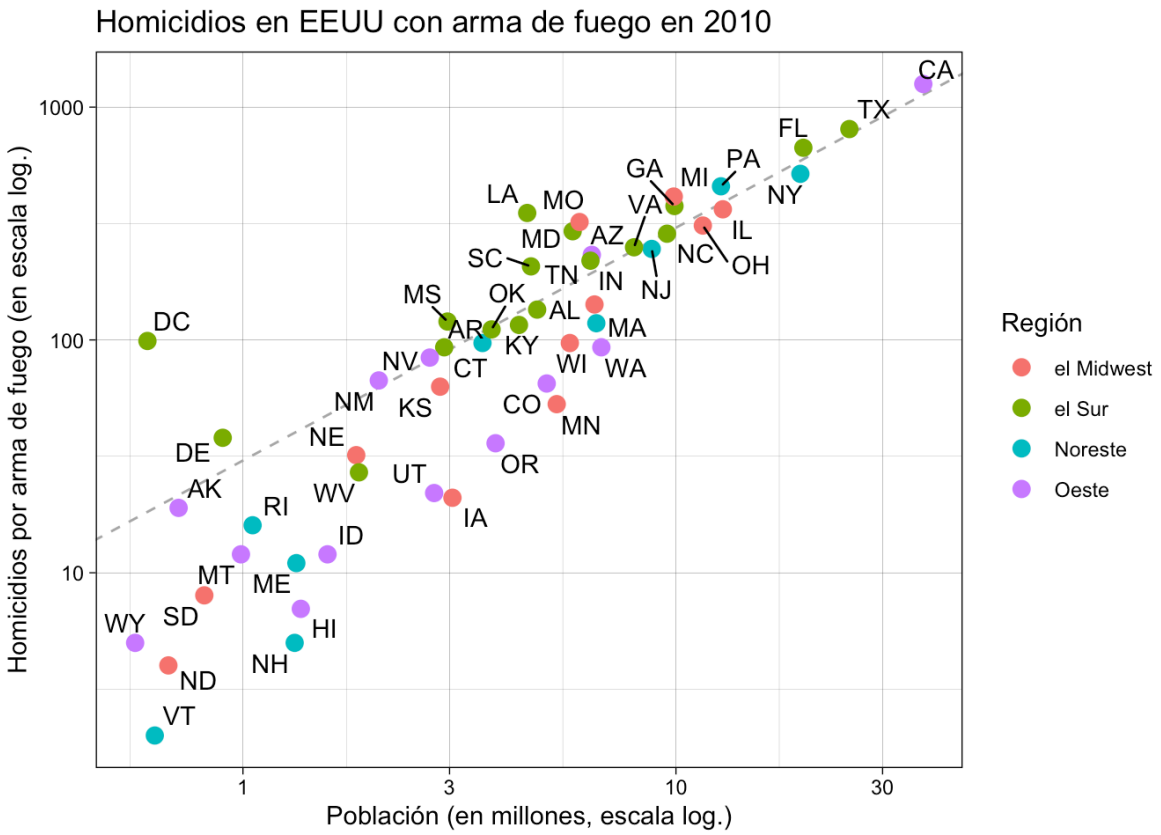

# Sección 3: Coeficiente de correlación

Nuevamente, mejor

# Coeficiente de Correlación: Definición

El **coeficiente de correlación de Pearson** ($\rho$) mide la fuerza y dirección de la relación lineal entre dos variables cuantitativas.

- $\rho$ toma valores entre $-1$ y $1$.
- $\rho = 1$: correlación positiva perfecta.
- $\rho = -1$: correlación negativa perfecta.
- $\rho = 0$: sin correlación lineal.

# Fórmula del Coeficiente de Correlación

La fórmula para calcular $\rho$ es:

$$\rho = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

Donde:

- $\text{Cov}(X, Y)$: covarianza entre $X$ y $Y$.
- $\sigma_X$: desviación estándar de $X$.
- $\sigma_Y$: desviación estándar de $Y$.

# Cálculo Paso a Paso

Para calcular $\rho$:

1. **Calcular las medias** de $X$ y $Y$:

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i, \quad \bar{Y} = \frac{1}{n}\sum_{i=1}^{n} Y_i$$

2. **Calcular la covarianza**:

$$\mathrm{Cov}(X, Y) = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y})$$

3. **Calcular las desviaciones estándar**:

$$\sigma_X = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2}, \quad \sigma_Y = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(Y_i - \bar{Y})^2}$$

4. **Calcular** $\rho$:

$$\rho = \frac{\mathrm{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

# Ejemplo Práctico

Supongamos las siguientes observaciones para $X$ e $Y$:

| $i$ | $X_i$ | $Y_i$ |
|---|---|---|
| 1 | 2 | 3 |
| 2 | 4 | 5 |
| 3 | 6 | 7 |
| 4 | 8 | 9 |
| 5 | 10 | 11 |

- $\bar{X} =$, $\bar{Y} =$
- $\text{Cov}(X, Y) =$
- $\sigma_X =$, $\sigma_Y =$
- $\rho = \frac{}{\times} = ?$

# Ejemplo Práctico

Supongamos las siguientes observaciones para $X$ e $Y$:

| $i$ | $X_i$ | $Y_i$ |
|---|---|---|
| 1 | 2 | 3 |
| 2 | 4 | 5 |
| 3 | 6 | 7 |
| 4 | 8 | 9 |
| 5 | 10 | 11 |

- $\bar{X} = 6,\ \bar{Y} = 7$
- $\text{Cov}(X, Y) = 10$
- $\sigma_X = 3{,}16,\ \sigma_Y = 3{,}16$
- $\rho = \frac{10}{3{,}16 \times 3{,}16} = 1$

**Interpretación:** Correlación positiva perfecta.

# Ejemplo Práctico: Correlación Negativa

Supongamos las siguientes observaciones para $X$ e $Y$:

| $i$ | $X_i$ | $Y_i$ |
|---|---|---|
| 1 | 1 | 10 |
| 2 | 2 | 8 |
| 3 | 3 | 6 |
| 4 | 4 | 4 |
| 5 | 5 | 2 |

- $\bar{X} = 3,\ \bar{Y} = 6$
- $\text{Cov}(X, Y) = -5$
- $\sigma_X = 1{,}58,\ \sigma_Y = 3{,}16$
- $\rho = \frac{-5}{1{,}58 \times 3{,}16} \approx -1$

**Interpretación:** Correlación negativa perfecta.

# Sección 4: Regresión lineal simple

Hacia el infinito

# Introducción a la regresión lineal simple

La **regresión lineal simple** permite predecir el valor de una variable, llamada **variable dependiente** o criterio (entre otros muchos nombres) (Y), a partir de otra variable conocida como **variable predictora** o independiente (X).

En el contexto de la regresión, la relación entre X e Y se representa mediante una línea recta, ajustando la relación para minimizar la distancia entre los puntos observados y la línea estimada.

# Fórmula de la Recta de Regresión

La ecuación de regresión lineal simple para predecir Y, $\hat{Y}$, a partir de X es:

$$\hat{Y} = a + bX$$

Donde:

- $a$ es la **intersección** o valor de Y cuando X es cero.
- $b$ es la **pendiente** o el cambio en Y esperado por cada unidad de cambio en X.

**Interpretación:** La pendiente ($b$) nos indica cuánto cambia Y en promedio por cada incremento de una unidad en X.

# Información previa a ejemplo: rango de puntuaciones del College Board

La prueba de admisión universitaria (PAA) en Puerto Rico tiene un rango de puntuaciones que va desde 600 hasta 2400 puntos. Este rango representa el desempeño de los estudiantes en las tres secciones de la prueba.
En el siguiente ejemplo, utilizaremos este rango para modelar la relación entre el puntaje de la PAA ($X$) y el GPA universitario ($Y$), que varía entre 0 y 4.0.

# Ejemplo: cálculo de la recta de regresión

Supongamos que queremos predecir el **gpa universitario** ($Y$) usando el **puntaje de College Board (PAA)** ($X$) de los estudiantes.

Dado un conjunto de datos, calculamos:

$$\hat{Y} = a + bX$$

Por ejemplo, si $a = 1{,}5$ y $b = 0{,}00104$, entonces para un puntaje PAA de 1200:

$$\hat{Y} = 1{,}5 + (0{,}00104 \times 1200) = 2{,}748$$

Este resultado indica que un puntaje de 1200 se asocia con un GPA universitario de aproximadamente 2.75.

# Interpretación de los coeficientes de regresión

En una regresión lineal, los coeficientes $a$ y $b$ tienen interpretaciones específicas:

- $a$: El intercepto indica el valor de $\hat{Y}$ cuando $X = 600$. En nuestro ejemplo, $a = 1{,}5$, lo que sugiere que un puntaje de 600 en la PAA se asocia con un GPA de 1.5.
- $b$: La pendiente muestra el cambio promedio en $Y$ por cada incremento de una unidad en $X$. En este caso, $b = 0{,}00104$ indica que por cada punto adicional en la PAA, se espera que el GPA aumente en 0.00104.

Estos coeficientes ayudan a comprender la relación entre las variables y permiten realizar predicciones informadas.

# Ejemplo adicional de predicción

Supongamos ahora que queremos predecir el **GPA** para un estudiante con un puntaje PAA de 2000.

$$\hat{Y} = 1{,}5 + (0{,}00104 \times 2000) = 3{,}58$$

Este cálculo sugiere que un puntaje de 2000 en la PAA se asocia con un GPA universitario de aproximadamente 3.58.
**Interpretación**: A medida que aumenta el puntaje en la PAA, el modelo predice un aumento en el GPA universitario, siguiendo la relación establecida por los coeficientes *a* y *b*.

# Notación estándar en regresión lineal

Para expresar la ecuación de regresión en términos más generales, usamos letras griegas para representar los parámetros y añadimos un término estocástico para capturar la variabilidad no explicada:

$$Y = \alpha + \beta X + \epsilon$$

Donde:

- $\alpha$ (alfa): Intercepto, el valor esperado de $Y$ cuando $X = 0$.
- $\beta$ (beta): Pendiente, cuánto cambia $Y$ en promedio por cada unidad adicional en $X$.
- $\epsilon$: Término de error, captura la variabilidad en $Y$ no explicada por $X$.

Este término estocástico $\epsilon$ reconoce que no toda la variación en $Y$ puede ser explicada perfectamente por $X$, que hay diferencias al tratar de trazar la línea que mejor explica la relación entre variables.

# Notación de vectores y matrices en regresión lineal

La regresión lineal puede representarse en términos de matrices y vectores para simplificar los cálculos y trabajar con múltiples predictores $(X_1, X_2, \ldots, X_K)$:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

Donde:

- $\mathbf{Y}$: Vector columna $(n \times 1)$ de valores observados de la variable dependiente.
- $\mathbf{X}$: Matriz de diseño $(n \times K)$, donde cada fila contiene las observaciones de los predictores.
- $\boldsymbol{\beta}$: Vector de parámetros $(K \times 1)$, incluyendo el intercepto y los coeficientes de los predictores.
- $\boldsymbol{\varepsilon}$: Vector de errores $(n \times 1)$, que captura la variabilidad no explicada.

# Dimensiones y transposición de matrices

Para trabajar con la notación matricial en regresión, es importante comprender las dimensiones y operaciones básicas:

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1K} \\ x_{21} & x_{22} & \dots & x_{2K} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{nK} \end{bmatrix}, \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_K \end{bmatrix}$$

- $\mathbf{X}$ es una matriz $n \times K$, donde $n$ es el número de observaciones y $K$ el número de predictores.
- $\mathbf{X}^\intercal$ es la transpuesta de $\mathbf{X}$, intercambiando filas y columnas.
- El producto $\mathbf{X}^\intercal\mathbf{X}$ genera una matriz cuadrada $K \times K$.

Ejemplo práctico:

$$\mathbf{X}^\intercal = \begin{bmatrix} x_{11} & x_{21} & \dots & x_{n1} \\ x_{12} & x_{22} & \dots & x_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ x_{1K} & x_{2K} & \dots & x_{nK} \end{bmatrix}$$

# Estimación de parámetros con mínimos cuadrados

El método de mínimos cuadrados en regresión busca minimizar la suma de los cuadrados de los residuos. En notación matricial, los coeficientes $\boldsymbol{\beta}$ se estiman como:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\intercal \mathbf{X})^{-1} \mathbf{X}^\intercal \mathbf{Y}$$

Pasos:

1. Calcular $\mathbf{X}^\intercal \mathbf{X}$: Multiplicación de la matriz de diseño por su transpuesta.
2. Invertir $(\mathbf{X}^\intercal \mathbf{X})$: Obtener la matriz inversa, si existe.
3. Calcular $\mathbf{X}^\intercal \mathbf{Y}$: Producto de la transpuesta de $\mathbf{X}$ con $\mathbf{Y}$.
4. Multiplicar los resultados: $(\mathbf{X}^\intercal \mathbf{X})^{-1} \mathbf{X}^\intercal \mathbf{Y}$.

Este procedimiento da como resultado los coeficientes que mejor ajustan la relación entre las variables.

# Matrices en regresión: introducción básica

Usamos matrices para representar los datos de manera compacta.
**Estructura de la matriz $\mathbf{X}$:**

$$\mathbf{X} = \begin{bmatrix} 1 & x_{11} \\ 1 & x_{21} \\ \vdots & \vdots \\ 1 & x_{n1} \end{bmatrix}$$

- La primera columna contiene valores constantes de 1, para incluir el intercepto ($\beta_0$, que no es más que el $\alpha$).
- La segunda columna contiene los valores de la variable predictora $X$ (en este caso, puntajes como $10, 15, 20$).

**Ejemplo práctico ($n = 3$):**

$$\mathbf{X} = \begin{bmatrix} 1 & 10 \\ 1 & 15 \\ 1 & 20 \end{bmatrix}, \quad \mathbf{Y} = \begin{bmatrix} 8 \\ 10 \\ 12 \end{bmatrix}$$

En los siguientes pasos, veremos cómo usar esta notación para calcular los coeficientes de regresión.

# Paso 1: transposición y producto de matrices

**La transpuesta de $\mathbf{X}$:**

$$\mathbf{X}^\intercal = \begin{bmatrix} 1 & 1 & 1 \\ 10 & 15 & 20 \end{bmatrix}$$

**Cálculo del producto $\mathbf{X}^\intercal\mathbf{X}$:**

$$\mathbf{X}^\intercal\mathbf{X} = \begin{bmatrix} 1 & 1 & 1 \\ 10 & 15 & 20 \end{bmatrix} \begin{bmatrix} 1 & 10 \\ 1 & 15 \\ 1 & 20 \end{bmatrix}$$

Resultado:

$$\mathbf{X}^\intercal\mathbf{X} = \begin{bmatrix} 3 & 45 \\ 45 & 725 \end{bmatrix}$$

**¿Qué significa esto?**

- Cada elemento de $\mathbf{X}^\intercal\mathbf{X}$ es el resultado de sumar productos correspondientes entre filas y columnas.
- Por ejemplo:

$$(\mathbf{X}^\intercal\mathbf{X})_{11} = 1 \cdot 1 + 1 \cdot 1 + 1 \cdot 1 = 3$$

$$(\mathbf{X}^\intercal\mathbf{X})_{12} = 1 \cdot 10 + 1 \cdot 15 + 1 \cdot 20 = 45$$

# Ejemplo práctico: continuación del cálculo matricial

**Cálculo del producto $\mathbf{X}^\intercal\mathbf{Y}$:**

$$\mathbf{X}^\intercal\mathbf{Y} = \begin{bmatrix} 1 & 1 & 1 \\ 10 & 15 & 20 \end{bmatrix} \begin{bmatrix} 8 \\ 10 \\ 12 \end{bmatrix}$$

Resultado:

$$\mathbf{X}^\intercal\mathbf{Y} = \begin{bmatrix} 30 \\ 525 \end{bmatrix}$$

**Inversión de la matriz $(\mathbf{X}^\intercal\mathbf{X})$:**

$$(\mathbf{X}^\intercal\mathbf{X})^{-1} = \begin{bmatrix} 2{,}42 & -0{,}15 \\ -0{,}15 & 0{,}01 \end{bmatrix}$$

**Cálculo de los coeficientes $\hat{\boldsymbol{\beta}}$:**

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\intercal\mathbf{X})^{-1}\mathbf{X}^\intercal\mathbf{Y} = \begin{bmatrix} 2{,}42 & -0{,}15 \\ -0{,}15 & 0{,}01 \end{bmatrix} \begin{bmatrix} 30 \\ 525 \end{bmatrix}$$

Que entonces es:

$$\hat{\boldsymbol{\beta}} = \begin{bmatrix} 5{,}0 \\ 0{,}5 \end{bmatrix}$$

La ecuación estimada es:

$$\hat{Y} = 5{,}0 + 0{,}5X$$

# Supuestos del modelo de regresión lineal

Para que los resultados de un modelo de regresión lineal sean confiables, debemos asumir ciertas condiciones:

- **A1. Linealidad:** La relación entre la variable dependiente $Y$ y las variables independientes $X_1, X_2, \ldots, X_K$ es lineal:

$$y_i = x_{i1}\beta_1 + x_{i2}\beta_2 + \cdots + x_{iK}\beta_K + \varepsilon_i$$

- **A2. Rango completo:** No hay relaciones lineales exactas entre las variables independientes ($X$). Es decir, hay independencia lineal de las variables
- **A3. Exogeneidad de las variables independientes:** El valor esperado del término de error ($\epsilon_i$) dado $X_1, X_2, \ldots, X_K$ es cero:

$$E[\varepsilon_i|X] = 0$$

Esto implica que las variables independientes no están correlacionadas con los errores.

# Supuestos del modelo de regresión lineal (continuación)

- **A4. Homocedasticidad y no autocorrelación:** Los errores ($\varepsilon_i$) tienen una varianza constante ($\sigma^2$) y no están correlacionados entre sí:

$$\text{Var}(\varepsilon_i) = \sigma^2, \quad \text{Cov}(\varepsilon_i, \varepsilon_j) = 0 \text{ para } i \neq j$$

- **A5. Generación de datos:** Los datos ($X$, $Y$) pueden ser constantes o variables aleatorias, pero las conclusiones se basan en la independencia de los errores y las variables independientes significadas en A3 y A4.
- **A6. Distribución normal:** Los errores ($\varepsilon_i$) están distribuidos normalmente:

$$\varepsilon_i \sim N(0, \sigma^2)$$

Este supuesto se puede relajar luego (con modelos que asuman otras distribuciones o con transformaciones), pero es útil para generar ciertos resultados estadísticos como intervalos de confianza y otras pruebas.

De violentarse estos supuestos, la validez de aspectos del modelo quedará cuestionada, y se deberán considerar alternativas varias. Entraremos a algunas de estas en las próximas clases.

# Sección 5: Varianza explicada y error de predicción

Nuevamente

# Evaluación del modelo de regresión

Para determinar la precisión y utilidad de nuestro modelo de regresión, consideramos:

- **Coeficiente de correlación** ($r$): Indica la fuerza y dirección de la relación entre $X$ y $Y$. En regresión simple, este valor describe la relación lineal entre las dos variables.
- **Coeficiente de determinación** ($R^2$): Representa la proporción de la variabilidad en $Y$ que puede ser explicada por $X$. Este coeficiente es $R^2 = r^2$ en el caso de regresión simple.
- **Errores de predicción** (residuos): Diferencia entre valores observados ($Y$) y predichos ($\hat{Y}$), evaluando así la precisión del modelo.

Usaremos nuestro ejemplo ($X = \begin{bmatrix} 10 \\ 15 \\ 20 \end{bmatrix}$, $Y = \begin{bmatrix} 8 \\ 10 \\ 12 \end{bmatrix}$) para calcular $R^2$ y analizar los residuos.

# Concepto de varianza explicada

La **varianza explicada** representa la parte de la variabilidad en la variable dependiente $Y$ que puede ser explicada por la variable independiente $X$ mediante el modelo de regresión.

- Nos ayuda a entender cuánto de la relación entre $X$ y $Y$ es capturada por el modelo.
- Se expresa a través del **coeficiente de determinación** $r^2$, el cual varía entre 0 y 1.
- Un $r^2$ cercano a 1 indica que la mayor parte de la variabilidad en $Y$ es explicada por $X$.

# Interpretación de $R^2$ y los residuos

**Coeficiente de determinación ($R^2$):**

- $R^2 = 1$: Toda la variabilidad en $Y$ es explicada por $X$ (modelo perfecto).
- $R^2 = 0$: El modelo no explica ninguna variabilidad en $Y$.
- Valores intermedios ($0 < R^2 < 1$): Indican una explicación parcial de la variabilidad en $Y$ por $X$.

**Residuos:**

$$\varepsilon_i = Y_i - \hat{Y}_i$$

Por ejemplo:

$$\mathbf{Y} = \begin{bmatrix} 8 \\ 10 \\ 12 \end{bmatrix}, \quad \hat{\mathbf{Y}} = \begin{bmatrix} 8 \\ 10 \\ 12 \end{bmatrix}, \quad \boldsymbol{\varepsilon} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

Un residuo cercano a 0 indica que el modelo predice bien esos puntos. En este caso, los residuos son exactamente 0, lo que sugiere un ajuste perfecto entre los valores observados y predichos.

# Cálculo de los valores predichos ($\hat{Y}$)

Con los coeficientes estimados $\beta_0 = 5{,}0$ y $\beta_1 = 0{,}5$, y los valores de $X_2 = \begin{bmatrix} 10 \\ 15 \\ 20 \end{bmatrix}$, calculamos los valores predichos ($\hat{Y}$) usando la ecuación:

$$\hat{Y} = \beta_0 + \beta_1 X_2$$

**Cálculos:**

$$\hat{Y}_1 = 5{,}0 + (0{,}5 \cdot 10) = 5{,}0 + 5{,}0 = 10{,}0,$$
$$\hat{Y}_2 = 5{,}0 + (0{,}5 \cdot 15) = 5{,}0 + 7{,}5 = 12{,}5,$$
$$\hat{Y}_3 = 5{,}0 + (0{,}5 \cdot 20) = 5{,}0 + 10{,}0 = 15{,}0.$$

**Resultado:**

$$\hat{\mathbf{Y}} = \begin{bmatrix} 10{,}0 \\ 12{,}5 \\ 15{,}0 \end{bmatrix}$$

Estos valores representan las predicciones del modelo para los

# Cálculo de los residuos ($\varepsilon$)

Los residuos ($\varepsilon_i$) se calculan como la diferencia entre los valores observados ($Y_i$) y los valores predichos ($\hat{Y}_i$):

$$\varepsilon_i = Y_i - \hat{Y}_i$$

Con $Y = \begin{bmatrix} 8 \\ 10 \\ 12 \end{bmatrix}$ y $\hat{Y} = \begin{bmatrix} 10{,}0 \\ 12{,}5 \\ 15{,}0 \end{bmatrix}$, los cálculos son:

$$\begin{aligned} \varepsilon_1 &= 8 - 10{,}0 = -2{,}0, \\ \varepsilon_2 &= 10 - 12{,}5 = -2{,}5, \\ \varepsilon_3 &= 12 - 15{,}0 = -3{,}0. \end{aligned}$$

**Resultado:**

$$\boldsymbol{\varepsilon} = \begin{bmatrix} -2{,}0 \\ -2{,}5 \\ -3{,}0 \end{bmatrix}$$

**Interpretación:**

- Los residuos representan la parte de $Y$ no explicada por el modelo para cada observación.
- Los valores negativos indican que el modelo sobreestimó los valores de $Y$.

# Cálculo del coeficiente de determinación ($R^2$)

El coeficiente de determinación $R^2$ se calcula como:

$$R^2 = \frac{\text{SS}_{\text{explicada}}}{\text{SS}_{\text{total}}} = 1 - \frac{\text{SS}_{\text{residual}}}{\text{SS}_{\text{total}}}$$

**Definiciones:**

- $\text{SS}_{\text{total}} = \sum_{i=1}^{n}(Y_i - \bar{Y})^2$: Variabilidad total en $Y$.
- $\text{SS}_{\text{explicada}} = \sum_{i=1}^{n}(\hat{Y}_i - \bar{Y})^2$: Variabilidad explicada por el modelo.
- $\text{SS}_{\text{residual}} = \sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2$: Variabilidad no explicada (errores).

Para nuestro ejemplo:

$$Y = \begin{bmatrix} 8 \\ 10 \\ 12 \end{bmatrix}, \quad \hat{Y} = \begin{bmatrix} 10 \\ 12{,}5 \\ 15 \end{bmatrix}, \quad \bar{Y} = 10.$$

Los cálculos serán desarrollados en la siguiente diapositiva.

# Cálculo de $R^2$ y componentes de suma de cuadrados

**Cálculos paso a paso:**

- $\mathsf{SS}_{\mathsf{total}} = (8-10)^2 + (10-10)^2 + (12-10)^2 = 4+0+4 = 8$
- $\mathsf{SS}_{\mathsf{residual}} = (8-10)^2 + (10-12{,}5)^2 + (12-15)^2 = 4 + 6{,}25 + 9 = 19{,}25$
- $\mathsf{SS}_{\mathsf{explicada}} = \mathsf{SS}_{\mathsf{total}} - \mathsf{SS}_{\mathsf{residual}} = 8 - 19{,}25 = -11{,}25$

**Coeficiente de determinación:**

$$R^2 = 1 - \frac{\mathsf{SS}_{\mathsf{residual}}}{\mathsf{SS}_{\mathsf{total}}} = 1 - \frac{19{,}25}{8} = -1{,}40625.$$

**Interpretación:**

- $R^2 < 0$: El modelo no solo no explica la variabilidad, sino que empeora el ajuste respecto a la media de $Y$.
- Esto indica posibles errores de especificación en el modelo o datos inconsistentes. Cabe señalar que este es un caso extremadamente raro.

# Cálculo del coeficiente de determinación ($R^2$)

Asumamos que las matrices y vectores son les siguientes:

$$Y = \begin{bmatrix} 9 \\ 11 \\ 13 \end{bmatrix}, \quad \hat{Y} = \begin{bmatrix} 10{,}0 \\ 11{,}5 \\ 13{,}0 \end{bmatrix}, \quad \bar{Y} = 11.$$

**Cálculos:**

- $\mathrm{SS}_{\text{total}} = (9-11)^2 + (11-11)^2 + (13-11)^2 = 8.$
- $\mathrm{SS}_{\text{residual}} = (9-10{,}0)^2 + (11-11{,}5)^2 + (13-13{,}0)^2 = 1{,}25.$
- $\mathrm{SS}_{\text{explicada}} = \mathrm{SS}_{\text{total}} - \mathrm{SS}_{\text{residual}} = 6{,}75.$

**Coeficiente de determinación:**

$$R^2 = 1 - \frac{\mathrm{SS}_{\text{residual}}}{\mathrm{SS}_{\text{total}}} = 1 - \frac{1{,}25}{8} = 0{,}84375.$$

**Interpretación:**

- El modelo explica el 84.375 % de la variabilidad en $Y$, lo cual indica un buen ajuste.
- El residuo ($\mathrm{SS}_{\text{residual}} = 1{,}25$) es bajo, lo que sugiere predicciones cercanas a los valores observados.

# Interpretación de $R^2$

El valor de $R^2$ tiene interpretaciones importantes en el contexto de regresión:

- Si $R^2 = 0$: Ninguna de la variabilidad en $Y$ es explicada por $X$; el modelo no tiene poder explicativo.
- Si $R^2 = 1$: Toda la variabilidad en $Y$ es explicada por $X$; el modelo es perfecto.
- Valores intermedios $(0 < R^2 < 1)$ indican un grado de explicación parcial, por ejemplo, $R^2 = 0{,}84375$ significa que el 84.375 % de la variabilidad en $Y$ es explicada por $X$.

**Nota**: En la práctica, un $R^2$ entre 0.3 y 0.5 suele considerarse moderado y aceptable en las ciencias sociales, mientras que valores más altos, como $R^2 = 0{,}84375$, indican un ajuste sólido (que podría invitar sospecha).

# Varianza no explicada (residuos)

La **varianza no explicada** es la parte de la variabilidad en $Y$ que no es explicada por el modelo, y se representa por los **residuos** ($\varepsilon$).

**Definición:**

$$\varepsilon_i = Y_i - \hat{Y}_i, \quad \text{con } \boldsymbol{\varepsilon} = \begin{bmatrix} -1 \\ -0{,}5 \\ 0 \end{bmatrix}.$$

**Suma de cuadrados de los residuos ($\mathbf{SS_{residual}}$):**

$$\mathrm{SS}_{\text{residual}} = \sum_{i=1}^{n} \varepsilon_i^2 = (-1)^2 + (-0{,}5)^2 + (0)^2 = 1 + 0{,}25 + 0 = 1{,}25.$$

**Interpretación:**

- Una $\mathrm{SS}_{\text{residual}}$ baja indica que el modelo predice bien los valores de $Y$.
- En este caso, $R^2 = 0{,}84375$, lo que sugiere que solo una pequeña parte de la variabilidad en $Y$ queda sin explicar.

# Conclusión de varianza explicada

En resumen:

- La **varianza explicada** ($R^2 = 0{,}84375$) indica que el 84.375 % de la variabilidad en $Y$ es capturada por el modelo de regresión.
- Un $R^2$ alto sugiere que el modelo se ajusta bien a los datos y explica la mayoría de las variaciones en $Y$.
- La **varianza no explicada** ($\mathrm{SS}_{\text{residual}} = 1{,}25$) es relativamente baja, reflejando una buena precisión del modelo.

Este análisis confirma que el modelo es útil para describir y predecir la relación entre $X$ y $Y$, con limitaciones mínimas en los residuos observados.

# Gráfico: salario vs educación con residuos

**Datos derivados de código de la secuencia de R.**

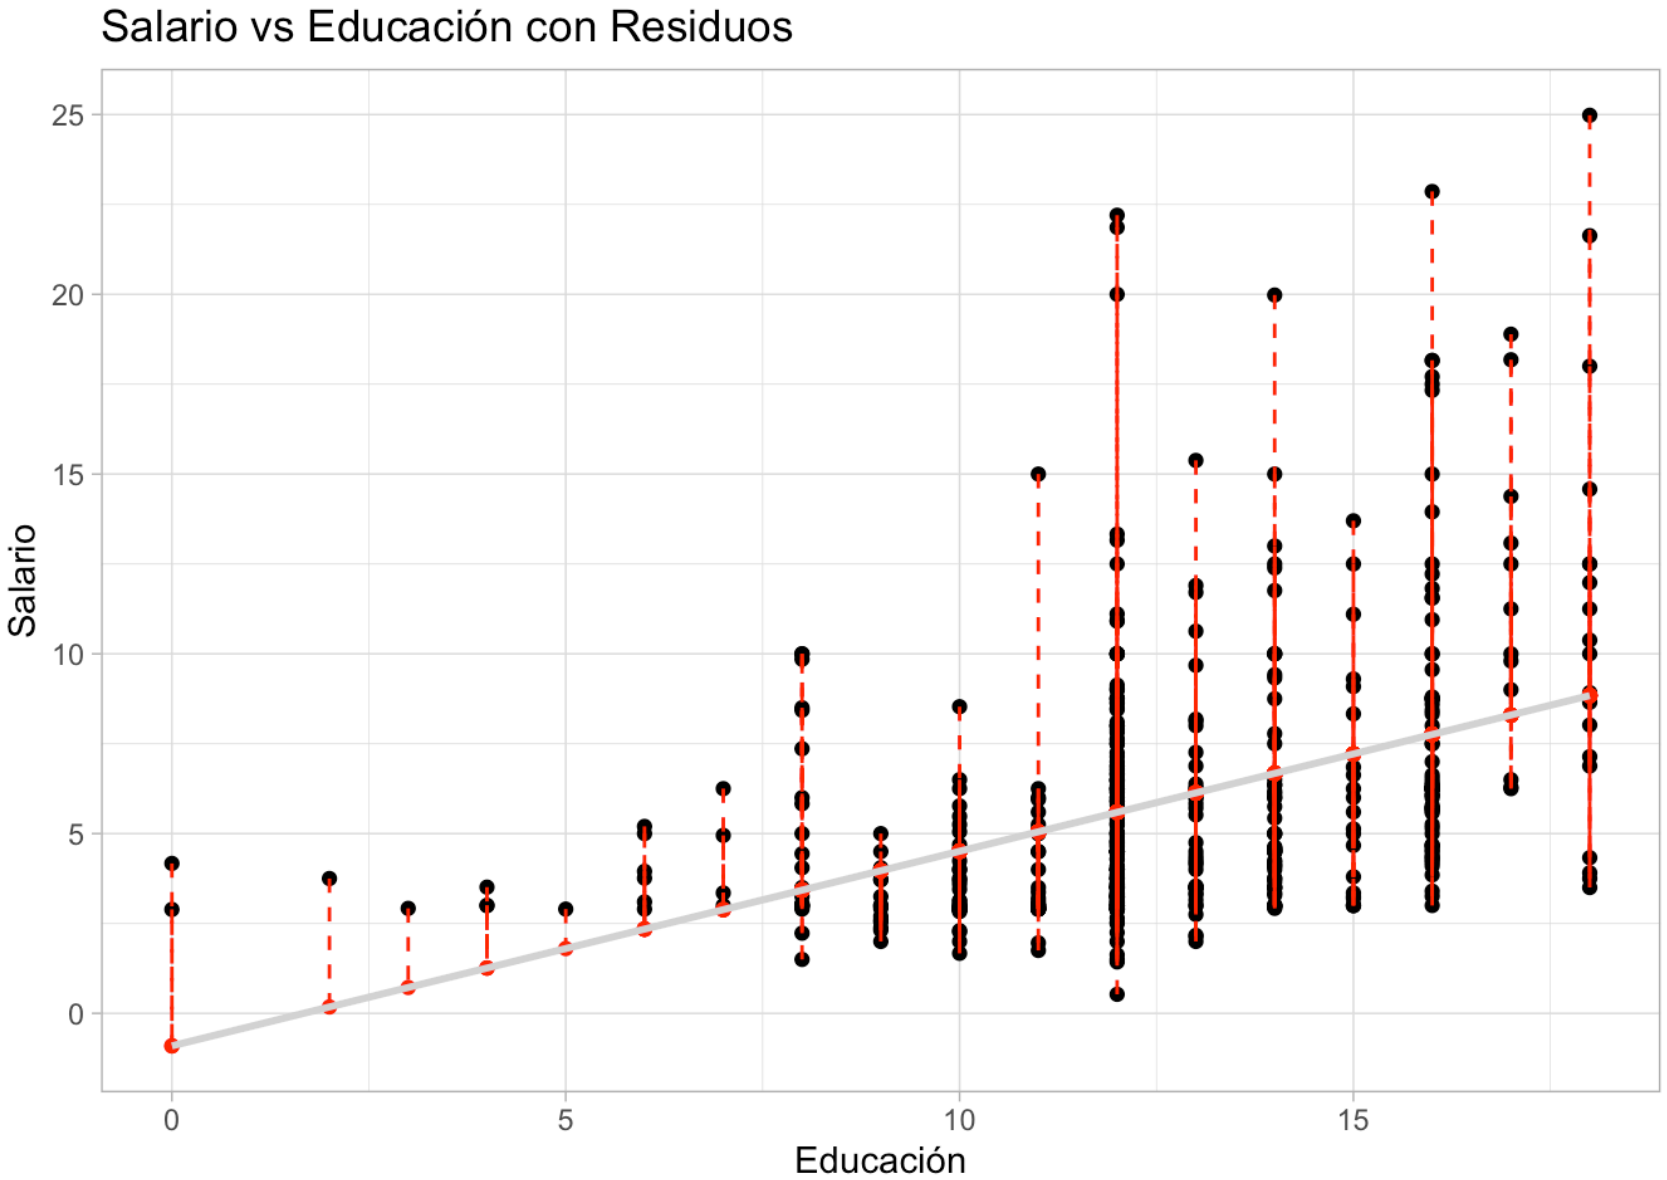

# Gráfico: salario vs educación con residuos

**Visualización de residuos:**

- La línea gris representa la relación predicha por el modelo de regresión.
- Los puntos negros son los valores observados ($Y$).
- Las líneas rojas representan los residuos ($\varepsilon = Y - \hat{Y}$), indicando la diferencia entre los valores observados y predichos.

**Interpretación:**

- Los residuos muestran un patrón moderado, indicando que el modelo captura bien la relación general entre educación y salario.
- Sin embargo, la dispersión de los residuos sugiere que puede haber variabilidad adicional no explicada por el modelo.

# Resumen de la sesión

Hoy discutimos los siguientes temas:

- **Correlación:** Cómo medir y cuantificar la relación entre dos variables cuantitativas.
- **Diagramas de dispersión:** Uso de gráficos para visualizar la relación entre variables.
- **Coeficiente de correlación:** Interpretación del coeficiente de Pearson para medir la fuerza y dirección de relaciones lineales.
- **Regresión lineal simple:** Predicción de una variable dependiente en función de una independiente mediante un modelo de regresión. En ese proceso tocamos adicional álgebra lineal para abundar mejor en cómo se calcula y ve el modelo.
- **Varianza explicada:** Evaluación del modelo de regresión usando el coeficiente de determinación ($R^2$).